

实验 A：A1 Controlled Replay 与 A3 Queue-Aware Replay 结果记录与解读

1. 对照 workbook 的实验目标

veriedge_revision_workbook.md 对实验 A 的目标定义是：

measured verifier profile 可以作为 placement 的硬约束，改变 heterogeneous edge LLM inference 的 placement frontier。

本交付包严格围绕 workbook 的 Experiment A 要求组织，只包含：

- A1 Controlled replay：closed-loop verifiability-constrained placement replay 主实验。
- A3 Queue-aware replay：在 queued workload 下加入 busy queue scoring 的补充消融。

2. 交付包目录

本交付包位于：

.

目录结构：

```
实验A交付物/
data/
  profile_matrix.csv
  candidate_placements.csv
  workload.csv
results/
  placement_runs.csv
  placement_summary.csv
  placement_summary_by_seed.csv
figures/
  fig_placement_frontier_a1.png / .pdf
  fig_placement_frontier_a3_queue.png / .pdf
  fig_risk_class_composition.png / .pdf
  fig_alpha_sensitivity_infeasible.png / .pdf
scripts/
  run_experiment_a_full.py
docs/
  veriedge_revision_workbook.md
  实验A_A1_A3结果记录与解读.md
metadata/
  environment.md
  git_commit.txt
  network_config.md
paper_snippets/
  abstract_numbers.txt
  figure_captions.txt
  placement_eval_subsection.tex
```

3. 输入数据

3.1 data/profile_matrix.csv

记录 measured verifier profiles。每一行对应一个 pair_id + sketch signature，包含：

- FPR: honest heterogeneous false-positive / false-dispute rate。
- TPR: material tamper true-positive rate。
- bytes trace: challenge trace reveal 数据量。
- verify latency: challenge-time verifier latency。
- risk class: low / medium / high / infeasible。

这些 profile 来自 20260512 的 measured verifier profile matrix，不是在实验 A 中现场合成。

3.2 data/candidate_placements.csv

记录 replay 中可选的 candidate placements，包括：

- group size
- provider set
- shard map
- pair ids
- network / execution latency
- availability cost
- reputation
- backend mix

Controlled replay 中 heterogeneous candidates 均按 group_size=3 组织；E/F 是 pair/profile label，不表示只用两台机器执行。

3.3 data/workload.csv

包含 single 与 queued-8 两类 workload。本报告重点解读 queued-8，alpha=0.10，beta=0.90，因为 workbook 要求 queued workload 并建议用该点作为主结果。

4. Feasibility 定义

candidate 被认为可裁决，需要满足：

```
capacity_ok == 1
group_size <= max_group_size
FPR(candidate, selected_sketch) <= alpha
TPR(candidate, selected_sketch) >= beta
bytes_trace(candidate, selected_sketch) <= sketch_budget_bytes
verify_ms(candidate, selected_sketch) <= verify_budget_ms
```

本实验主设置：

参数	数值	含义
alpha	0.10	honest execution 被误判为异常的上限
beta	0.90	material tamper 检出率下限
sketch_budget_bytes	3072	challenge trace reveal 数据量预算

参数	数值	含义
verify_budget_ms	5.0	verifier challenge latency 预算
challenge_prob	0.10	false risk / challenge workload 计算中的 challenge 概率

5. Policy 分组

5.1 A1 Controlled Replay Policies

Policy	定义	作用
network_aware_scalar	按 latency/network 选 group, 固定 scalar16	原始弱 baseline
network_aware_projcos4	按 latency/network 选 group, 固定 projcos4	公平 fixed-sketch baseline
verif_constrained_projcos4	固定 projcos4 , 先过滤不满足约束的 candidate	主 hard-filter policy
network_aware_adaptive	先按 latency 选 group, 再为该 group 选最小可行 sketch	验证 sketch upgrade
adaptive_verifier	同时选择 group 和最小可行 sketch	验证 joint group/sketch selection
homogeneous_only	只允许 homogeneous candidate	保守对照

5.2 A3 Queue-Aware Policies

queue-aware policies 在 score 中加入当前 candidate 的排队等待：

```
score(candidate) =
  estimated_latency(candidate, task)
+ max(0, busy_until[candidate] - arrival_s)
+ verifier/risk/sketch penalty
```

Policy	定义	作用
queue_aware_network	queue-aware score, 固定 scalar16 , 不做 verifier hard filtering	检查 queue-aware load balancing 本身是否足够
queue_aware_verif_constrained	queue-aware score + 固定 projcos4 hard filtering	检查 queue-aware + verifier constraint
queue_aware_adaptive	queue-aware score + 最小可行 sketch selection	检查 queue-aware + adaptive verifier

6. 主结果表

queued=8, alpha=0.10, beta=0.90 :

Policy	Median latency	P95 latency	Goodput	Challenge ms/task	False risk	Infeasible	Low-risk	Admission
network_aware_scalar	90.156	170.384	1.079	0.360	0.0165	1.000	0.000	1.000
network_aware_projcos4	90.156	170.384	1.079	0.380	0.0105	1.000	0.000	1.000
verif_constrained_projcos4	91.844	173.576	1.060	0.380	0.0020	0.000	1.000	1.000
network_aware_adaptive	90.156	170.384	1.079	0.392	0.0005	0.000	1.000	1.000

Policy	Median latency	P95 latency	Goodput	Challenge ms/task	False risk	Infeasible	Low-risk	Admission
adaptive_verifier	91.844	173.576	1.060	0.380	0.0020	0.000	1.000	1.000
queue_aware_network	5.522	9.757	12.266	0.360	0.0142	0.935	0.065	1.000
queue_aware_verif_constrained	7.004	12.714	10.392	0.380	0.0033	0.000	1.000	1.000
queue_aware_adaptive	5.457	9.781	12.251	0.380	0.0028	0.000	1.000	1.000
homogeneous_only	119.301	225.498	0.822	0.360	0.0000	0.000	1.000	1.000

7. A1 结果解读

7.1 network_aware_scalar

network_aware_scalar 只按 latency/network 选 group，并固定使用 scalar16 verifier。结果：

- goodput = 1.079
- false risk = 0.0165
- infeasible rate = 1.000

这支持 workbook 的 H1：低延迟 placement 会选中不可裁决的 heterogeneous signature。

7.2 network_aware_projcos4

network_aware_projcos4 是公平 fixed-sketch baseline。它已经把 verifier 从 scalar16 换成 projcos4，但仍然只按 latency/network 选 group，不做 hard filtering。

结果仍然：

- infeasible rate = 1.000
- false risk = 0.0105

这说明问题不只是 scalar16 太弱，而是 placement policy 没有用 verifier profile 过滤不可行 candidate。单纯换 verifier sketch，不等于 closed-loop placement。

7.3 verif_constrained_projcos4

verif_constrained_projcos4 使用同一个 fixed sketch projcos4，但会在 placement 前过滤违反 alpha/beta/B/C 的 candidate。

结果：

- infeasible rate 从 1.000 降到 0.000
- false risk 从 0.0105 降到 0.0020
- goodput 从 1.079 小幅降到 1.060

这支持 workbook 的 H2：verifiability-constrained placement 可以过滤 risky signatures，使 infeasible usage 接近 0。

7.4 network_aware_adaptive 与 adaptive_verifier

network_aware_adaptive 保留 latency-preferred group，但升级 sketch：

- infeasible rate = 0.000
- false risk = 0.0005
- goodput = 1.079

`adaptive_verifier` 同时考虑 `group` 和 `sketch`，当前选择更低 `sketch cost` 的 `feasible combination`：

- `infeasible rate` = 0.000
- `false risk` = 0.0020
- `goodput` = 1.060

这支持 workbook 的 H4：adaptive-verifier policy 可以通过升级 `sketch` 或改变 `group/sketch` 组合来满足 `alpha/beta target`。

7.5 对 H3 的解读

H3 要求观察 `queued workload` 下 `goodput` 是否显著受损。

在 non-queue-aware A1 主机制实验中：

- `network_aware_projcos4 goodput` = 1.079
- `verif_constrained_projcos4 goodput` = 1.060

下降约 1.8%，属于小幅 `tradeoff`。因此可以写成：

hard filtering removes infeasible placements with only a modest goodput change in this replay.

但不能把它写成 live scheduler 结论，因为这是 offline replay。

8. A3 Queue-Aware 结果解读

A3 的目的不是替代 A1，而是补强 workbook 对 `queued workload / goodput` 的要求。它回答：

如果 policy 选择 placement 时已经考虑 `busy queue`，`verifier constraints` 是否仍然必要？

结果显示：

8.1 Queue-aware 明显改善 queued workload

`queue_aware_network` 相比 `network_aware_scalar`：

- median latency 从 90.156 降到 5.522
- p95 latency 从 170.384 降到 9.757
- `goodput` 从 1.079 提升到 12.266

这说明把 `busy_until` 纳入 `score` 后，policy 不再把所有任务压到同一个最快 `candidate`，而是能分散负载。

8.2 Queue-aware 不能替代 verifier constraints

`queue_aware_network` 虽然 `goodput` 高，但：

- `infeasible rate` = 0.935
- `low-risk share` = 0.065

也就是说，queue-aware load balancing 只解决拥塞，不解决 `verifier infeasibility`。

8.3 Queue-aware + verifier constraints 才是正确组合

`queue_aware_verif_constrained`：

- `goodput` = 10.392
- `infeasible rate` = 0.000
- `false risk` = 0.0033

queue_aware_adaptive :

- goodput = 12.251
- infeasible rate = 0.000
- false risk = 0.0028


这说明即使调度器已经 queue-aware，仍然需要 verifier profile 作为 placement-time admission / sketch-selection constraint。

9. 图表说明

Figure A1a: A1 Placement Frontier

文件:

- fig_placement_frontier_a1.png
- figures/fig_placement_frontier_a1.pdf




含义：只展示 A1 controlled replay 的 placement/verifier frontier，横轴是 median latency，纵轴是 false risk。把 A1 单独成图后，重点更清楚：latency-oriented baseline 倾向选择更快但 infeasible 的 signature；verifiability-constrained / adaptive policies 用 verifier profile 在 placement 前筛掉或升级不可行 signature，把结果推向 feasible / low-risk 区域。

Figure A1b: A3 Queue-Aware Frontier

文件:

- fig_placement_frontier_a3_queue.png
- figures/fig_placement_frontier_a3_queue.pdf




含义：只展示 A3 queue-aware policies。这里加入了 current queue wait 后，median latency 和 goodput 明显改善；但 queue_aware_network 仍会选择 infeasible signatures，说明 queue-aware scoring 解决的是排队等待问题，不能替代 verifiability constraint。

Figure A2: Risk-Class Composition

文件：

- fig_risk_class_composition.png
- figures/fig_risk_class_composition.pdf



含义：展示各 policy 选中 placements 的 low-risk / infeasible 比例。network_aware_* 和 queue_aware_network 仍有 infeasible slice；verif_constrained / adaptive policies 将 infeasible 降到 0。

纵坐标缩写含义：


缩写	完整 policy	含义
N-scalar	network_aware_scalar	只按 network/latency 选 group，固定 scalar16
N-proj4	network_aware_projcos4	只按 network/latency 选 group，固定 projcos4
VC-proj4	verif_constrained_projcos4	固定 projcos4，并过滤不可行 candidate
N-adapt	network_aware_adaptive	先按 network/latency 选 group，再升级到最小可行 sketch
Adaptive	adaptive_verifier	group 与 sketch 联合选择
Q-network	queue_aware_network	queue-aware score，固定 scalar16，不做 verifier hard filtering
Q-VC	queue_aware_verif_constrained	queue-aware score + projcos4 hard filtering
Q-adapt	queue_aware_adaptive	queue-aware score + adaptive verifier
Homo-only	homogeneous_only	只允许 homogeneous candidate

Figure A3: Alpha Sensitivity

文件：

- fig_alpha_sensitivity_infeasible.png
- figures/fig_alpha_sensitivity_infeasible.pdf

Alpha sensitivity: stricter targets increase baseline infeasibility



含义：展示 $\alpha = 0.05 / 0.10 / 0.20$ 下 infeasible rate 的变化，证明结论不是只依赖单点 $\alpha=0.10$ 。新版图只保留 workbook 主线相关 policy，并分成 A1 机制组与 A3 queue-aware 组两个面板；由于多条线在 0 或 1 处重合，图中改用面板下方图例而不是线尾标签，避免标签堆叠。读图重点是：

- network_aware_scalar / network_aware_projcos4 在严格 alpha 下保持高 infeasible。
- verif_constrained_projcos4 / adaptive_verifier 在 sweep 中保持 infeasible 为 0。
- queue_aware_network 即使考虑 busy queue，仍有较高 infeasible；queue_aware_verif_constrained / queue_aware_adaptive 仍保持 infeasible 为 0。

10. 对 workbook 假设的回答

Workbook 假设	是否支持	证据
H1. Network-aware / cost-only 会选择低 latency 但不可裁决的 heterogeneous pairs	支持	network_aware_projcos4 infeasible rate = 1.000
H2. Verifiability-constrained placement 会过滤这些 pairs，使 infeasible usage 接近 0	支持	verif_constrained_projcos4 infeasible rate = 0.000
H3. queued workload 下过滤 risky signatures 不一定显著损失 goodput	支持但需谨慎	A1 goodput 从 1.079 到 1.060；A3 queue-aware constrained goodput = 10.392
H4. Adaptive-verifier policy 可以升级 sketch mode 保留更多 candidate	支持	network_aware_adaptive infeasible = 0.000 且 goodput = 1.079；queue_aware_adaptive goodput = 12.251

11. 可写进论文的结论

可以写：

- Closed-loop placement replay shows that measured verifier profiles can be used before disclosure as admission constraints.
- Under queued-8, $\alpha=0.10$, fixed projcos4 network-aware placement still selects infeasible signatures, while verif_constrained_projcos4 reduces infeasible usage from 1.000 to 0.000.
- Adaptive verifier selection can satisfy the target by upgrading sketch or choosing another feasible group/sketch combination.
- Queue-aware placement improves queued replay latency/goodput, but queue-awareness alone does not remove verifier infeasibility; queue-aware verifier-constrained/adaptive policies reduce infeasible usage to 0.000.

需要谨慎写：

- 这是 offline replay，不是 live scheduler deployment。

- controlled replay 的 candidate latency 是受控构造，用来演示 workbook 要求的 closed-loop mechanism。
- Goodput 可以作为 replay 指标，但不能夸大成真实系统吞吐。

不能写：

- 不能说所有真实 workload 下 hard filtering 都无代价。
- 不能说 verifier profile 证明了语义正确性；它证明的是在论文定义的 checkpoint/profile 范围内可裁决。
- 不能把 A2/A4 robustness/stress 结论混进本交付包的主实验结论。

12. 推荐论文段落

Closed-loop placement changes which heterogeneous executions are admitted before task disclosure. Under the queued-8 wc

To account for queued workload effects, we additionally evaluate queue-aware policies that include current candidate wa

13. 最终判断

按照 workbook 要求，当前 A1 + A3 已经可以作为实验 A 的正式交付：

- 输入文件齐全。
- policy ablation 齐全。
- queued workload 齐全。
- alpha sweep 齐全。
- placement frontier / risk composition / alpha sensitivity 图齐全。
- placement_runs.csv 与 placement_summary.csv 齐全。
- 结果能够回答 H1-H4。