

SignRadial 快速验证实验 — 汇总报告

实验日期：2026-08-06 ~ 2026-08-07


实验目录：workspace/SRR/





核心方法：SignRadial (p=1 radial coefficient)

$$S_1 = \frac{|\sum_i \text{sign}(x_i)(y_i - x_i)|}{\sum_i |x_i|}$$

一句话结论：SignRadial 用符号抵消分离"相干误差 vs 不相干噪声"，**稳定检测 scale / 低精度 / replay 攻击**，是本次验证选出的最优径向检测器；与 ProjCos 组成双头可覆盖全部盲点。


图像索引：全部实验图内嵌如下 (fig1–fig10)。






Method comparison: SignRadial solves the scale blind spot with zero FPR


Scale-attack detection (higher=better)





Honest FPR (lower=better)




P2a: honest noise floor falls $\sim 1/\sqrt{q}$, scale signal is constant







P2b2: per-token scaling (alternating alpha) — both weak



P3b: partial replay — 10% token replay already detected




P5a: honest SignRadial per layer — needs per-layer gamma (8.7x spread)




P4b: W8A16 (weight-only) invisible to SignRadial, W8A8 (weight+act) detectable

W8A16 vs W8A8: SignRadial separation



Detection rate vs honest thresholds



目录

- 1. 方法定位

- 2. 实验清单与状态
- 3. P0: exact-replay 边界（概念）
- 4. P1a: sign-balanced 攻击（双头互补）
- 5. P1b: 真实低精度作弊（threat model 核心）
- 6. P2a: q 标度律 + u_i 机制
- 7. P2b: balanced per-channel scaling（SignRadial 压力测试）
- 8. P2b2: per-token scaling
- 9. P3b: partial replay
- 10. P5a: 逐层阈值
- 11. P4b: W8A16 vs W8A8（RTX3090）
- 12. 汇总：盲点覆盖图
- 13. 结论与建议

1. 方法定位

问题：projcos 只看方向（scale 盲点，scale TPR=0.0107）、scalar 只看数值（方向盲）。需要同时覆盖两者且轻量的方法。

演进：SRR（energy）→ S_parallel（radial p=2）→ **SignRadial（radial p=1）**。前两者在量化异构环境失效（honest 漂移 > scale 攻击），SignRadial 用 sign(x) 模板解决。

结论：SRR（energy）和 S_parallel（radial p=2）在量化异构环境失效——honest 漂移（A 配对 C1 |a|_p99=0.386）> scale 攻击（0.10），信噪比不可分。SignRadial 用符号抵消解决。

为什么有效：sign(x)·(y-x) 让 honest 量化噪声（不相干、正负混合）**符号抵消**，scale 攻击（相干、全同号）**同号累积**。honest noise floor $\propto 1/\sqrt{q}$ ，scale 信号恒定。

2. 实验清单与状态

实验	内容	状态	关键结果
P0	exact-replay 边界	✓	数值正确缓存=0，需 nonce，非验证器缺陷
P1a	sign-balanced 攻击	✓	SignRadial=0，ProjCos=1.0 → 双头互补
P1b	真实 BF16→FP8/INT8/INT4	✓	FP8/INT4 秒抓；INT8 多边界可覆盖

实验	内容	状态	关键结果
P2a	q 标度律 + u_i 直方图	✓	honest $\propto 1/\sqrt{q}$ (4.13 $\approx$ 4); u_i 符号抵消
P2b	balanced per-channel scaling	✓	SignRadial 失效、ProjCos 补回
P2b2	per-token scaling	✓	两者都弱 (幅值小)
P3b	partial replay	✓	10% token 就检测 75%
P5a	逐层阈值	✓	需逐层 γ (跨层 8.7 $\times$)
P4b	W8A16 vs W8A8	✓	W8A16 不可见、W8A8 可检测

3. P0: exact-replay 边界（概念）

结论：SignRadial（及任何数值比较检测器）对"重放数值正确的缓存激活"输出 0——因为从数值上看它就是正确答案。

- 检测的是 **stale activation incompatible with current computation**，不是 **cryptographic freshness**。
- 若威胁模型要求"证明本次真实重算"，需 nonce/canary/commitment 机制。
- 论文威胁模型必须写清此边界。

详见 P0_EXACT_REPLAY_BOUNDARY.md 。

4. P1a: sign-balanced 攻击（双头互补）

攻击：构造 $\text{sign}(x)^T e = 0$ （正交化精确归零，null_check=1e-14）。

幅度 c	SignRadial	SRR	ProjCos4	ProjCos16
0.3	0.000	0.000	0.760	0.825
0.5	0.000	0.000	0.985	1.000
1.0	0.000	0.000	1.000	1.000

结论：sign-balanced 攻击让 SignRadial 和 SRR 完全失效，ProjCos 精准补回。双头真正互补：

- **SignRadial** 检测 coherent magnitude cheating
- **ProjCos** 检测 angular redistribution

5. P1b: 真实低精度作弊（threat model 核心）

设计：恶意节点**整个 forward 用低精度算术**（每层 Linear 权重量化到目标精度 + activation 量化，误差逐层传播），边界激活 cast 回 BF16。同设备 BF16 对照（honest~honest=0.0000 逐 bit 一致）。

执行：Mac mini M4（MPS），Qwen3-0.6B，10 prompts。诚实披露：MPS 无原生低精度 mm，matmul 在 fp32 但操作数是量化值（误差传播真实）。

结果（SignRadial, layer 16）：

精度	mean	min	max	检测判定
honest~honest	0.0000	0.0000	0.0000	—
INT8	0.083	0.041	0.128	边界：C2/C3 100%、仅 C1 70%
FP8	0.978	0.961	0.998	秒抓（15-80× honest）
INT4	0.943	0.911	0.973	秒抓

结论：FP8/INT4 精度作弊被 SignRadial 稳定检测（真实逐层低精度 forward 产生的相干漂移）。INT8 是攻击者"甜点"，但**多边界检查（C1+C2+C3）**可覆盖。

详见 P1B_PRECISION_CHEATING.md 。

6. P2a: q 标度律 + u_i 机制

机制证据（非 TPR 表）：

q 标度律（honest C1 p99, 3 seeds）：

q	16	32	64	128	256	512	1024
A/B	0.244	0.186	0.085	0.059	0.043	0.026	0.024
scale 1.1×	—	—	—	—	0.10	0.10	0.10

1/√q 验证： p99(16)/p99(256)=4.13（预期 4）、p99(256)/p99(1024)=2.41（预期 2）。**q=64 交叉**（honest<scale），q=256 有 2.4× 余量。对比 SRR 的 O(1) noise floor——**本质区别**。

u_i 符号抵消（u_i = sign(x)(y-x)）：

场景	mean	正侧占比
honest C1	+0.003	0.47（平衡）
scale 1.1×	+0.126	1.00 （全正）
scale 0.9×	-0.126	0.00 （全负）

结论： SignRadial 测"误差是否与参考相干"，不是"误差多大"。honest 不相干（抵消）、scale 相干（累积）。

图： fig5_q_scaling.png ， fig6_ui_hist.png 。详见 P2A_Q_SCALING.md 。

7. P2b: balanced per-channel scaling（SignRadial 压力测试）

攻击： 一半 hidden channel 乘 α_up，一半乘 α_dn（分子中 +c|x| 与 -c|x| 抵消）。

α_up/α_dn	SignRadial	ProjCos4
1.1/0.9	0.000	1.000
1.2/0.8	0.005	1.000
1.3/0.7	0.105	1.000
1.5/0.5	0.440	1.000

结论： balanced per-channel scaling 是 SignRadial 的真盲点（α=1.1/0.9 时 TPR=0，因为 +0.2|x| 和 -0.2|x| 完全抵消），**ProjCos** 全检出。双头互补的又一强证据。

8. P2b2: per-token scaling（交替 α ）

幅度	SignRadial	ProjCos4
0.1	0.000	0.000
0.2	0.025	0.000
0.3	0.145	0.000

结论：per-token 交替缩放对两者都弱（幅值小、逐 token 抵消）。不是主要威胁。

9. P3b: partial replay

攻击：p_replay 比例的 token 从上一 prompt 替换。

p_replay	SignRadial	ProjCos4
10%	0.750	0.995
25%	0.995	0.995
50%	0.995	0.995
100%	0.995	0.995

结论：SignRadial **10% token 重放就检测 75%**（q=256 采样命中足够篡改坐标），25%+ 全检出。对稀疏篡改不敏感——最小篡改量很低。

10. P5a: 逐层阈值

层	honest p50	p90	p99	max
C1（早）	0.009	0.032	0.061	0.073
C2（中）	0.005	0.015	0.036	0.044

层	honest p50	p90	p99	max
C3（晚）	0.002	0.004	0.007	0.010

结论：honest p99 跨层差 **8.7×**（0.061 vs 0.007）→ **必须逐层校准 γ** （ $\Gamma_{\text{model, layer, backend}}$ ），不能用单一全局阈值。与部署建议一致。

11. P4b: W8A16 vs W8A8（RTX3090）

威胁区分：W8A16（仅权重 int8，activation 保持 fp16，bitsandbytes 真实内核）vs W8A8（权重+activation 都 int8）。

结果（SignRadial, layer 16, 10 prompts）：

配置	mean	min	max	检出率（C2/C3 honest p99）
honest~honest	0.0000	0.0000	0.0000	—
W8A16	0.0051	0.0014	0.0094	0%
W8A8	0.0830	0.0438	0.1311	100%

结论（决定性差异）：

- **W8A16（weight-only）** 对 SignRadial 不可见（0.005 < honest p99 0.012~0.06）——activation 无相干漂移，这是 SignRadial 的已知盲区，必须诚实披露。覆盖需输出级检测（judge/KL）或权重 commitment。
- **W8A8（weight+activation）** 可检测（0.083 > C2/C3 honest p99，100% 检出）——activation 也量化，误差逐层传播。

详见 P4B_W8A16_VS_W8A8.md 。

12. 汇总：盲点覆盖图

攻击族	SignRadial	ProjCos4	谁负责
scale 1.10×	✅ 1.0	❌ 0.0	SignRadial

攻击族	SignRadial	ProjCos4	谁负责
真实精度作弊 FP8/INT4	✅ ~0.98	(待测)	SignRadial
真实精度作弊 INT8	✅ 边界 (多边界 100%)	—	SignRadial+ 多边界
W8A8 (weight+act int8)	✅ 0.083>honest	(待测)	SignRadial
W8A16 (weight-only int8)	❌ 不可见	(待测)	需输出级检测
replay / stale / wrong_prompt	✅ 0.995	✅ 1.0	两者
partial replay 10%	✅ 0.75	✅ 0.995	两者
layer_skip	✅ 1.0	✅ 1.0	两者
sign-balanced 攻击	❌ 0.0	✅ 1.0	ProjCos
balanced per-channel scaling	❌ 0.0-0.005	✅ 1.0	ProjCos
per-token scaling	弱	弱	低威胁
exact replay	❌ 0.0	❌ 0.0	非数值问题, 需 nonce

最终架构：Radial detector (SignRadial) + Angular detector (ProjCos)，OR 报警。两者盲点不重叠、互补，覆盖全部实际攻击族。

13. 结论与建议

13.1 方法结论

- SignRadial 是最优径向检测器：O(q) 纯加减、无随机投影 seed、直接测 $|\alpha-1|$ 、honest noise floor $\propto 1/\sqrt{q}$ 。
- SignRadial 单独覆盖方向和数值：scale、精度作弊 (FP8/INT4/W8A8)、replay、layer_skip 全检出。
- SignRadial 有三个真盲点：sign-balanced 攻击、balanced per-channel scaling (ProjCos 补回)、W8A16 weight-only (需输出级检测)。

4. 校准必须逐层 ($\Gamma_{\text{model,layer,backend}}$)。

13.2 对论文 (NDSS) 的建议

- **新贡献点**: SignRadial (径向检测) + ProjCos (角向检测) 双头结构, 相干/不相干误差分离机制。
- **诚实边界**: exact-replay 需 nonce (非数值问题); sign-balanced/balanced-channel 是白盒自适应攻击的已知盲点, ProjCos 补回; **W8A16 weight-only 是 activation-based 检测的固有盲区**。
- **机制证据**: q 标度律 + u_i 直方图 (P2a) 比 TPR 表更能说服。

13.3 未做 (需更多时间的实验)

- P4a: partial precision (25/50/75/100% 层低精度) —— 需 P1b harness 扩展
- P4c: 输出退化 (token disagreement/KL) —— 需 decode 路径
- P5b: prompt/seq-len/domain 泛化 —— 需新 prompts 跑模型
- previous-token replay (decode 场景) —— 需 decode 路径

产物清单

```
workspace/SRR/
├─ srr.py                # SRR (V2: 独立坐标 + B_min)
├─ radial.py            # SignRadial (sign_radial) + S_parallel
├─ baselines.py         # scalar/projcos/projscalar (复用 frozen hash_chain)
├─ attacks.py          # 全部攻击族 (gaussian/scale/per-channel/per-token/part
├─ run_srr_offline.py   # SRR vs baseline 全表 runner
├─ p1a_sign_balanced.py # P1a
├─ p1b_full.py          # P1b (mini 执行)
├─ p4b_w8a16_vs_w8a8.py # P4b (RTX3090 执行)
├─ p2a_plot.py          # P2a 出图
├─ p2b_p3b_p5a.py       # P2b/P2b2/P3b/P5a 组合
├─ results/
│   └─ srr_vs_baseline.csv # 36 行主表
│   └─ figures/           # fig1-fig11
└─ docs/
    ├─ P0_EXACT_REPLAY_BOUNDARY.md
    ├─ P1B_PRECISION_CHEATING.md
    ├─ P2A_Q_SCALING.md
    ├─ P4B_W8A16_VS_W8A8.md
    ├─ SRR_DELIVERY_HANDBOOK.md
    ├─ SRR_DELIVERY_HANDBOOK_V2_ADDENDUM.md
    ├─ SRR_DELIVERY_HANDBOOK_V3_ADDENDUM.md
    └─ SRR_CONSOLIDATED_SUMMARY.md # 本文件
```